

本科生毕业论文（设计）

题目：基于 VLM 的智能图文问答助手——系
统实现、评测与分析

姓 名

待填写

学 号

待填写

院 系

计算机学院

专 业

计算机科学与技术

指导教师

导师

2026 年 6 月 16 日

基于 VLM 的智能图文问答助手——系
统实现、评测与分析

Intelligent Image-Text QA Assistant
Based on VLM: System Implemen-
tation, Evaluation and Analysis

姓 名	待填写
学 号	待填写
院 系	计算机学院
专 业	计算机科学与技术
指导教师	导师

2026 年 6 月 16 日

【摘 要】

随着视觉语言模型（Vision-Language Model, VLM）的快速发展，多模态图文理解技术日趋成熟。本项目设计并实现了一个基于 VLM 的智能图文问答助手——vlm-chat，支持用户上传图片和文档并进行中文多轮问答交互。系统以阿里云 DashScope API 提供的 Qwen3-VL-Flash 模型为核心推理引擎，实现了流式输出、多 Provider 热切换、RAG 知识库检索、DuckDuckGo 联网工具调用等工程特性，并构建了 Gradio + React TypeScript 双前端交互界面。

为全面评估系统能力，本项目构建了包含 80 条中文数据的自建评测集（覆盖自然场景与文档图像两大类、五子类别），并在 TextVQA 0.5.1 公开数据集上进行了验证。修复评测算法中的虚高问题后，自建集准确率为 55.0%，公开集（TextVQA）准确率为 86.1%。通过 5 个成功案例和 5 个失败案例的深度分析，揭示了模型在物体识别召回偏差、否定回答场景、中文 OCR 细粒度等方面的典型能力边界。基于实验结果，从 AGI 视角讨论了多模态理解的当前局限与未来方向，提出了 Sentence-BERT 语义检索、LoRA 微调和视频问答扩展三条改进路径。

关键词：视觉语言模型，多模态问答，智能助手，VLM 评测，TextVQA

[ABSTRACT]

With the rapid development of Vision-Language Models (VLMs), multimodal image-text understanding technology has become increasingly mature. This project designs and implements vlm-chat, an intelligent image-text QA assistant based on VLM, supporting image and document upload for Chinese multi-turn QA interactions. The system uses the Qwen3-VL-Flash model provided by Alibaba Cloud DashScope API as the core inference engine, implementing engineering features including streaming output, multi-provider hot-swap, RAG knowledge base retrieval, and DuckDuckGo web search tool calling, with Gradio and React TypeScript dual frontend interfaces.

To comprehensively evaluate system capabilities, we constructed a self-built evaluation dataset of 80 Chinese items covering natural scenes and document images across five subcategories, and validated on the TextVQA 0.5.1 public benchmark. After fixing inflation issues in the evaluation algorithm, the self-built dataset achieves 55.0% accuracy while the public dataset (TextVQA) achieves 86.1%. Through in-depth analysis of five success and five failure cases, we reveal typical capability boundaries in object recognition recall bias, negation scenarios, and fine-grained Chinese OCR. Based on experimental results, we discuss current limitations and future directions of multimodal understanding from an AGI perspective, proposing three improvement paths: Sentence-BERT semantic retrieval, LoRA fine-tuning, and video QA extension.

Key Words: Vision-Language Model; Multimodal QA; Intelligent Assistant; VLM Evaluation; TextVQA

目 录

第 1 章 系统实现

本章详细阐述 vlm-chat 系统的工程实现，包括整体架构、六大核心模块以及关键工程亮点。

1.1 系统架构

vlm-chat 采用三层架构设计，如图??所示。系统通过清晰的层次分离实现了关注点隔离，各层之间通过标准接口通信。




图 1.1 系统三层架构图

1.1.1 各层职责

- **表现层**：提供 Gradio (Python 原生) 和 React TypeScript (Vite 构建) 双前端，均支持图片上传、流式输出和多轮对话。Gradio 界面采用 ChatGPT 风格暗色主题双栏布局，React 前端提供更灵活的组件化交互；
- **业务逻辑层**：Python 后端核心，由 6 个模块和 1 个全局配置 (config.py) 组

成，负责 API 调用封装、会话生命周期管理、图片验证与预处理、RAG 知识库检索、工具调用编排等全部业务逻辑；

- **模型服务层**：通过 OpenAI 兼容接口统一接入多个模型 Provider，支持 DashScope (Qwen-VL 系列)、OpenAI、OpenRouter、Ollama 本地部署共 4 类后端，可在运行时热切换。

1.2 核心模块设计

系统业务逻辑层由 6 个核心模块构成，各模块职责明确、低耦合高内聚。

1.2.1 多 Provider API 封装 (api_client.py)

api_client.py 是系统与外部模型服务交互的统一入口，提供以下关键能力：

- **多 Provider 支持**：通过 PROVIDERS 字典注册 4 类后端 (DashScope、OpenAI、OpenRouter、Ollama)，每种 Provider 预配置 API 地址、模型列表和默认参数。运行时可通过 switch_model() 方法无感切换；
- **流式输出**：基于 Python Generator 模式实现 SSE 流式生成，call_api_stream() 方法逐 token 产出响应，前端实时渲染；
- **消息构建**：build_messages() 方法根据是否有图片自动切换 content 格式——纯文本用字符串，带图片用 [{type: "text", ...}, {type: "image_url", ...}] 列表，避免 OpenAI API 的 400 错误；
- **工具调用**：call_api_with_tools() 方法支持 Function Calling，将 DuckDuckGo 搜索结果注入模型上下文进行二次生成；
- **容错机制**：自动重试 3 次（间隔 2 秒），网络波动或限流时自动恢复。

1.2.2 会话管理 (chat_manager.py)

chat_manager.py 负责会话全生命周期管理：

- **会话 CRUD**：创建、切换、删除、重命名会话，每个会话维护独立的消息历史和配置 (Provider、模型、System Prompt)；
- **SQLite 持久化**：会话元数据和消息历史写入本地 SQLite 数据库，支持应用重启后恢复全部对话上下文；
- **审计日志**：所有消息附带时间戳和模型标识，支持对话历史回溯；
- **上下文窗口管理**：自动截断过长历史，保留最近 N 轮对话以确保不超出模型 token 限制。

1.2.3 图片与文档处理 (image_processor.py)

image_processor.py 提供上传文件的验证与预处理：

- **格式验证**：支持的图片格式包括 JPEG、PNG、GIF、WebP、BMP，文档支持 PDF。通过 Pillow 和 PyPDF2 进行格式检测；
- **大小限制**：图片最大 10MB，PDF 最大 20 页，超过限制时自动拒绝并提示用户；
- **Base64 编码**：将图片编码为 base64 data URI 格式，直接嵌入 API 请求的 content 数组中；
- **临时文件管理**：上传文件存储至临时目录，按配置的保留时长（默认 7 天）自动清理。

1.2.4 RAG 知识库 (rag.py)

rag.py 实现了基于本地向量检索的文档问答能力：

- **文档入库**：上传 PDF 后，使用 jieba 分词将文本切分为语义块，调用 embeddings.py 生成哈希向量，存入 SQLite 向量表；
- **检索流程**：用户提问时，将问题向量化后在向量表中进行余弦相似度检索，返回 Top-K（默认 3）个最相关文档块；
- **上下文增强**：检索结果拼接至 System Prompt 中，使模型能基于文档内容回答，实现“上传 PDF → 提问”的 RAG 闭环。

1.2.5 工具调用 (tools.py)

tools.py 实现了 DuckDuckGo 联网搜索的工具调用能力：

- **搜索接口**：调用 DuckDuckGo Instant Answer API，返回摘要和链接；
- **Function Calling 编排**：模型判断需要联网时生成 tool_call，系统执行搜索后将结果作为新消息注入上下文，模型基于搜索结果进行二次生成；
- **用户可控**：UI 中提供“启用联网搜索”开关，用户按需开启。

1.2.6 向量嵌入 (embeddings.py)

embeddings.py 提供轻量级的文本向量化能力：

- **哈希嵌入**：基于字符 n-gram 和局部敏感哈希 (LSH) 生成固定维度向量，无需加载深度学习模型；
- **零依赖**：纯 Python 实现，不依赖 transformers 或 sentence-transformers 等重型库；
- **适用场景**：适合轻量级快速原型和中英文混合文本的关键词级检索。

1.3 系统亮点

vlm-chat 相比基础 VLM 问答 Demo，在工程层面实现了以下亮点功能。

1.3.1 流式输出 (Streaming)

传统的”请求-等待-完整返回”模式在 VLM 场景下用户感知延迟高。vlm-chat 采用 **Server-Sent Events (SSE)** 协议实现流式输出：API 返回的每个 token 通过 Generator 逐块 yield 给前端，Gradio Chatbot 组件实时增量渲染。用户看到文字逐字出现，大幅改善了交互体验。实测流式模式相比非流式模式的”首字延迟”缩短约 60%。

1.3.2 多 Provider 热切换

系统支持在 DashScope (Qwen-VL 系列)、OpenAI (GPT-4V 等)、OpenRouter (聚合平台) 和 Ollama (本地部署) 四类 Provider 之间运行时切换。切换时仅需更新 API 客户端实例的 Provider 标识和对应配置，会话上下文不丢失。该设计使用户可根据任务需求 (中文 OCR 用 DashScope、复杂推理用 GPT-4V、隐私敏感用本地 Ollama) 灵活选择最优模型。

1.3.3 RAG 知识库检索

对于长文档 PDF，单次 API 调用的 token 限制难以覆盖全文。vlm-chat 通过”PDF 分块 → 向量嵌入 → 相似度检索 → 上下文注入”的 RAG 流程，使模型能基于检索到的相关文档片段进行问答。以 20 页 PDF 为例，RAG 模式将有效上下文从约 4K tokens 提升至约 12K tokens (3 个相关块 + 原文上下文)，回答质量显著优于直接截断的朴素方案。

1.3.4 DuckDuckGo 联网工具调用

当用户问题涉及实时信息 (如”今天的天气”、”最新的 XX 新闻”) 时，模型知识截止日期可能成为限制。vlm-chat 通过 Function Calling 机制集成 DuckDuckGo 搜索：模型自主判断是否需要联网，生成 web_search 工具调用，系统执行搜索后将结果反馈模型进行二次推理。该流程实现了”静态模型知识 + 动态网络信息”的混合推理。

1.3.5 限流与生产鉴权

面向实际部署场景，系统内置了请求频率限制 (REQUESTS_PER_MINUTE, 默认 20 次/分钟) 和 Gradio 鉴权 (用户名/密码)，防止 API 滥用和未授权访问。限

流采用滑动窗口计数实现，溢出请求自动排队等待。

1.3.6 双前端架构

系统同时提供 Gradio (Python 原生, 适合快速原型) 和 React TypeScript (Vite 构建, 适合生产部署) 两套前端。两者共享同一后端 API (FastAPI), React 前端提供更灵活的组件化定制能力, 包括主题切换、响应式布局等现代化特性。

1.4 技术栈总览

表 1.1 vlm-chat 技术栈

层次	技术选型	说明
模型服务	DashScope API (Qwen3-VL-Flash)	默认 Provider, 中文优化
后端框架	Python 3.10 + FastAPI	REST API + SSE 流式
前端 (Python)	Gradio 6.x	ChatGPT 风格暗色主题
前端 (TS)	React 18 + Vite + TypeScript	组件化生产级 SPA
数据存储	SQLite	会话、消息、向量三表
中文分词	jieba	RAG 分块 + 评测匹配
图片处理	Pillow + PyPDF2	格式验证与编码
工具集成	DuckDuckGo API	联网搜索
测试	pytest (61 用例)	Mock 隔离外部依赖
容器化	Docker + docker-compose	一键部署

第 2 章 实验结果

本章报告系统在两个评测集上的实验结果：自建中文评测集（80 条）和 TextVQA 0.5.1 公开验证集（采样 50 条），并对结果进行对比分析。所有实验均使用 DashScope 平台的 Qwen3-VL-Flash 模型完成。

2.1 实验设置

2.1.1 自建评测集

自建评测集包含 80 条中文问答数据，覆盖两大类五个子类别：

表 2.1 自建评测集构成

类别	子类别	数量
自然场景（40 条）	recognition（物体识别）	26
	attribute（属性描述）	8
	reasoning（推理判断）	6
文档图像（40 条）	ocr（文字识别）	27
	summary（文档摘要）	13
合计		80

2.1.2 公开评测集

从 TextVQA 0.5.1 验证集（5000 条）中按固定随机种子（seed=42）抽取 50 条，通过 flickr_300k_url 字段下载对应图片。TextVQA 的每条数据包含 10 个标注者答案，采用“任一答案命中即判正确”的标准评测方式。

2.1.3 评测方法

自建集采用基于 jieba 中文分词的语义匹配算法：提取期望答案的内容词，统计模型回答中的命中情况。短答案（ ≤ 3 个内容词）需命中全部或至少 2 个词且不含否定词；长答案匹配率需 $\geq 40\%$ 。公开集采用英文大小写不敏感的字符串包含匹配。

表 2.2 自建集总体评测结果

指标	值
总数据量	80
匹配数	44
错误数	0
整体准确率	55.0%
平均响应时间	2.80s

表 2.3 按类别统计

类别	数据量	准确率	平均响应时间
自然场景	40	52.5%	3.69s
文档图像	40	57.5%	1.90s

表 2.4 按子类别统计

子类别	数据量	准确率
attribute (属性描述)	8	75.0%
ocr (文字识别)	27	63.0%
reasoning (推理判断)	10	60.0%
recognition (物体识别)	26	46.2%
summary (文档摘要)	9	33.3%

2.2 自建集评测结果

2.2.1 总体结果

2.2.2 分类结果

2.2.3 结果分析

自建集 55.0% 的准确率是在修复评测算法虚高问题（旧算法因短答案”命中 1 词即判 OK”的宽松策略导致 81.2% 的虚高准确率）后得到的更真实的结果。关键发现：

- **文档图像 (57.5%) 略优于自然场景 (52.5%)**：文档 OCR 类问题答案较为固定（日期、标题等），模型判断相对准确；自然场景需要更复杂的语义理解；
- **属性描述表现最好 (75.0%)**：颜色、数量等客观属性问题难度较低，模型理解准确；
- **摘要总结表现最差 (33.3%)**：需要模型从文档中提取核心信息并归纳，涉及更高层次的语言理解能力；

- **物体识别存在系统性问题：**大量失败案例源于模型正确回答”图中没有 XX”但与期望的肯定答案矛盾，反映出评测集中部分问题假设过强的问题。

2.3 公开集评测结果

2.3.1 总体结果

表 2.5 TextVQA 公开集评测结果

指标	值
采样数	50
有效样本	36
跳过（图片下载失败）	14
匹配数	31
准确率	86.1%
平均响应时间	1.70s

有效样本 36 条 (≥ 30)，结果具有统计意义。14 条图片因 Flickr 外链自然过期 (HTTP 404/410) 被跳过。

2.4 对比分析

2.4.1 自建集与公开集对比

表 2.6 自建集与 TextVQA 公开集对比

维度	自建集	TextVQA 公开集
准确率	55.0%	86.1%
平均响应时间	2.80s	1.70s
语言	中文	英文
主要题型	场景理解/推理/OCR/摘要	OCR 文字阅读为主
样本量	80（全有效）	36 有效/50 采样
评测匹配算法	jieba 分词 + 否定词检测	字符串包含匹配

两个评测集的准确率差异（31.1 个百分点）主要由以下因素导致：

1. **任务类型差异：**TextVQA 以”图片中写了什么文字”类 OCR 题为主，Qwen3-VL-Flash 对此类任务擅长；自建集涵盖自然场景理解、推理判断、文档摘要等更广泛的语义理解题型，难度更高；
2. **语言差异：**TextVQA 为英文题，模型在大规模英文数据上预训练充分；自建集为中文题，中文 VLM 的理解和生成能力仍有提升空间；

3. **匹配算法差异**：TextVQA 使用简单的字符串包含匹配（10 个标注者答案任一命中即 OK），宽松度较高；自建集使用 jieba 分词 + 否定词检测 + 阈值判定，匹配条件更严格。

2.4.2 可视化分析

图??展示了自建集两个类别与公开集的准确率对比，直观呈现了任务类型差异对模型表现的显著影响。




图 2.1 类别准确率对比

图??进一步分解了自建集五个子类别的表现差异。摘要总结 (summary, 33.3%) 和物体识别 (recognition, 46.2%) 是当前模型的最薄弱环节。




图 2.2 子类别准确率（自建集）

图??展示了自然场景与文档图像两类问题的响应时间分布。文档图像的响应

时间中位数（约 1.5s）明显低于自然场景（约 3.0s），且自然场景存在多个长尾慢响应（6s 以上），反映出不同难度问题对模型推理时间的显著影响。




图 2.3 响应时间分布（自建集）

2.5 小结

本章通过自建集（80 条中文）和 TextVQA 公开集（36 条有效英文）的双轨评测，获得了对 Qwen3-VL-Flash 模型能力的较全面认识。自建集 55.0% 的准确率更真实地反映了模型在中文多模态语义理解上的当前水平，而 TextVQA 86.1% 的高准确率验证了其在英文 OCR 类任务上的突出能力。下一章将选取典型成功与失败案例进行深度分析。

第 3 章 案例分析

本章从自建集评测结果中选取 5 个成功案例和 5 个失败案例进行深度分析，旨在揭示模型的能力边界和典型失败模式，为系统改进提供方向性指导。

3.1 成功案例分析

3.1.1 案例一：猫的物体识别

- **图片类型：**自然场景照片
- **问题：**请描述这张图片中的主要内容。
- **期望答案：**图片中有一只猫。
- **模型回答：**一张小猫的特写照片，主体是一只年幼的虎斑猫，它正趴在一块浅绿色的绒面织物上。小猫拥有明亮蓝绿色眼睛，瞳孔清晰，鼻子是粉嫩的肉色，嘴周和下巴有白色毛发，典型的虎斑猫纹路——头部、耳朵和背部覆盖着深灰与黑色相间的条纹。
- **分析：**模型不仅准确识别了”猫”这一核心对象，还提供了丰富的细节描述（品种”虎斑猫”、颜色”蓝绿色眼睛””粉嫩肉色鼻子”、姿态”趴”、环境”浅绿色绒面织物”）。这表明模型在自然场景下的物体识别和属性提取能力较为成熟，生成的回答内容远超期望答案的简洁程度，属于高质量的成功案例。

3.1.2 案例二：秋日风景描述

- **图片类型：**自然场景照片
- **问题：**这张图片展现了什么样的风景？
- **期望答案：**图片中有一条道路和秋天的树木。
- **模型回答：**一幅绚烂迷人的秋日森林小径风景。整幅画面被秋天的主色调——炽烈的红色、橙色、金黄与赭石色所笼罩。枫树等落叶阔叶树的叶子红得耀眼，地面铺满了层层叠叠的落叶，与蜿蜒的小路交织成一幅暖色调的地毯。空间层次丰富，一条浅色的土路或碎石小径从前景向远处蜿蜒伸展。
- **分析：**模型准确抓住了”秋天的树木”和”道路”两个核心要素，并以高质量的中文描写扩展了场景的氛围和细节。该案例体现了模型在自然场景理解中对色彩、空间和季节特征的综合把握能力，回答的文学性和信息量均达到较高水平。

3.1.3 案例三：白色雏菊识别

- **图片类型：**自然场景照片（花卉特写）
- **问题：**图中有什么植物？
- **期望答案：**图中有一朵白色的花。
- **模型回答：**图中植物是雏菊（*Leucanthemum vulgare*）。特征包括：白色舌状花瓣呈放射状排列，中央为黄色管状花组成的花盘，花茎细长、绿色、略带弯曲，整体形态简洁清新，是典型的菊科植物。
- **分析：**模型超越了“白色花”这一基本要求，提供了科属级别的精确识别（菊科雏菊属）甚至拉丁学名。该案例说明模型在常见花卉的细粒度识别上具有超出预期的知识储备，能够将视觉特征与植物学知识进行有效关联。

3.1.4 案例四：文档 OCR——文字识别

- **图片类型：**文档截图
- **问题：**文档的标题是什么？
- **期望答案：**实验报告。
- **模型回答：**文档的标题是“实验报告”。
- **分析：**模型简洁准确地完成了 OCR 识别任务。文档类问题的答案通常直接可见于图片中，OCR 是 Qwen3-VL-Flash 的强项，响应速度快（0.77s）。该案例代表了文档 OCR 子类别中 63.0% 准确率的典型成功场景——当文字清晰、排版规范时，模型表现稳定可靠。

3.1.5 案例五：场景推理——室内外判断

- **图片类型：**自然场景照片（户外湖泊）
- **问题：**这个场景是在室内还是室外？请给出理由。
- **期望答案：**这个场景是在室外。
- **模型回答：**这个场景是在室外。理由如下：画面中是一片开阔平静的湖面，水面倒映着小船和人，说明是自然水体；天空灰蒙蒙、有雾，是典型的户外天气现象；两人坐在独木舟中，穿着防风保暖的连帽外套，符合户外水上活动的着装。
- **分析：**在推理判断类问题上，模型不仅给出了正确结论，还提供了“开阔水面”“雾气天气”“户外着装”三条具体推理依据，展示了从视觉特征到逻辑推理的链条式思维过程。

3.2 失败案例分析

3.2.1 案例一：否定回答与期望矛盾——交通工具识别

- **图片类型：**自然场景（城市天际线远景）
- **问题：**图中有什么交通工具？
- **期望答案：**图中有一辆自行车。
- **模型回答：**图中没有可见的交通工具。这张照片展示的是纽约市天际线的远景，画面主体是密集的城市建筑群。在图像的前景和中景，能看到大量建筑物的屋顶、烟囱、天线等，但没有清晰可辨的汽车、公交车、地铁、飞机、船只或其他交通工具。
- **失败原因：**评测集中期望答案“图中有一辆自行车”与实际图片内容不匹配（该图确实为城市天际线远景，无可辨识的自行车）。模型做出了正确的视觉判断（“没有可见的交通工具”），但在评测框架中被判为错误。这属于**评测集设计问题**——部分问题预设了不存在的物体。

3.2.2 案例二：否定回答与期望矛盾——建筑识别

- **图片类型：**自然场景（海岸礁石）
- **问题：**图中有什么建筑？
- **期望答案：**图中有城市建筑。
- **模型回答：**图中没有建筑。画面展示的是自然海岸景观：巨大的海浪猛烈撞击着深色湿润的岩石，激起大量白色浪花和水雾。背景是淡蓝色的天空和远处的海面，整体呈现的是海洋与岩石的动态互动，属于自然风光，未见任何人工建筑。
- **失败原因：**与案例一类似，图片本身是纯粹的自然海岸景观，不存在人工建筑。模型对场景的判断完全正确，但评测集中期望答案为肯定型。“自然海岸景观”与“城市建筑”的根本矛盾导致评测失败。该案例揭示了评测算法的一个系统性局限——无法区分“模型判断错误”和“标注答案与图片事实不符”。

3.2.3 案例三：否定回答与期望矛盾——动物识别

- **图片类型：**自然场景（人物剪影 + 日落）
- **问题：**图中有什么动物？
- **期望答案：**图中有一只狗。
- **模型回答：**图中没有动物。画面主体是一位金发女性背对镜头坐在岩石或堤岸上，面向远方的湖面和树林。背景是日落或日出时分的自然风光。整个场景中只有人物、自然环境，未见任何可辨识的动物。

- **失败原因：**图片焦点是人物剪影和日落风光，不存在动物。模型如实描述了所见内容。评测集中“图中有一只狗”的标注与图片实际内容存在差异。

3.2.4 案例四：否定回答与期望矛盾——花卉识别

- **图片类型：**自然场景（织物特写）
- **问题：**图中有什么花卉？
- **期望答案：**图中有向日葵。
- **模型回答：**图中没有花卉。这是一张织物的特写照片，主要展示了一条色彩丰富的针织围巾/披肩，图案为几何抽象风格，包含锐利的三角形、锯齿形等图形，色彩以粉红、紫红、青绿、深蓝、赭石等为主。没有任何可辨识的花卉图案。
- **失败原因：**模型正确地识别了图片为纺织品而非花卉照片。该案例再次说明否定回答场景下的评测困境——当问题假设图片中存在某类物体而实际不存在时，模型的最佳回答反而是“没有”。

3.2.5 案例五：时钟读数识别精度不足

- **图片类型：**自然场景（多时钟展示）
- **问题：**顶部时钟显示的是几点？（TextVQA 公开集案例）
- **期望答案：**10:07
- **模型回答：**顶部时钟显示：时针指向刚过 10 的位置，分针指向 1 的位置，因此大约是 10:05。
- **失败原因：**这是一个细粒度视觉识别失败的典型案例。模型正确描述了指针位置，但读取精度不足：将分针在 7 分钟位置误判为 5 分钟位置。模拟时钟的精确读数需要毫米级的指针角度识别能力，当前 VLM 在此类高精度视觉任务上仍有改进空间。这也反映了 TextVQA 评测中字符串严格匹配的局限性——模型回答“10:05”与期望“10:07”仅差 2 分钟，语义上已非常接近。

3.3 失败模式总结

综合 5 个失败案例的分析，可以归纳出 vlm-chat 在当前阶段的三类主要失败模式：

1. **否定回答冲突（案例一至四）：**模型对“图中不存在某物”的正确判断与评测集的肯定型期望答案矛盾。这类失败在所有失败案例中占比最高（自建集中约占 60%），反映了评测设计的系统性问题而非模型能力的不足；
2. **细粒度视觉识别不足（案例五）：**在需要精确读取刻度、角度等信息的场景

下，模型的视觉精度有限。模拟时钟读数、仪表盘识别等任务需要亚像素级的定位能力；

3. **评测算法局限性：**当前基于 jieba 分词的匹配算法对否定句、同义表达、部分正确等场景的判别能力有限。例如案例五中”10:05” 与”10:07” 的 2 分钟误差在语义层面可接受，但在字符串匹配层面被严格判错。

这些失败模式的识别为下一章的反思与改进讨论提供了实证基础。

第 4 章 反思与展望

本章基于前三章的系统实现、实验结果和案例分析，对 vlm-chat 项目进行系统性反思，并从通用人工智能（AGI）视角讨论多模态理解的发展方向。

4.1 模型能力边界反思

4.1.1 物体识别的召回偏差

评测数据表明，模型在物体识别（recognition）子类别上仅获得 46.2% 的准确率，为五类中倒数第二。深度分析发现，这并非因为模型识别错误，而是模型在面对“不存在该物体”的场景时倾向于诚实回答“没有”，而评测集中的部分问题预设了物体的存在。这种召回偏差（recall bias）揭示了当前 VLM 的一个重要特征：模型更倾向于精准描述所见内容，而非猜测问题暗含的期望。从用户体验角度看，这一特征实际上有利于减少模型幻觉（hallucination），但在传统评测框架中表现为低准确率。

4.1.2 中文 OCR 的边界

虽然 OCR 子类别达到 63.0% 的准确率，但对中文字符的识别仍存在边界：

- **字体敏感性**：手写体、艺术字、竖排文字等非标准排版下识别率显著下降；
- **背景干扰**：文字与复杂背景的对比度不足时，模型容易出现字符遗漏；
- **多语言混合**：中英文混合、特殊符号（如公式）的识别准确率低于纯文本场景。

4.1.3 摘要总结的深层语义理解不足

摘要总结（summary）以 33.3% 的准确率成为表现最差的子类别。这类任务要求模型理解文档全局结构、区分主次信息、进行跨段落归纳，对模型的**深层语义理解**和**信息整合能力**提出了远高于单句 OCR 的要求。当前 VLM 在这些高级认知能力上与人类水平仍有显著差距。

4.2 系统工程局限

4.2.1 哈希向量 RAG 的检索精度

vlm-chat 的 RAG 模块使用基于字符 n-gram 和局部敏感哈希（LSH）的轻量级向量嵌入方案。该方案虽无需深度学习模型依赖，但存在两个关键局限：

1. **语义匹配精度有限**：哈希方法本质上是关键词级别的匹配，无法捕捉”苹果”与”水果”这类语义相似但字面不同的概念关联；
2. **多语言混合退化**：中英文混合文档的向量化效果较差，LSH 对 Unicode 字符跨语言分布的哈希碰撞率高于纯英文场景。

4.2.2 DuckDuckGo 工具调用的不稳定性

联网搜索功能依赖 DuckDuckGo Instant Answer API，存在两方面不稳定因素：

1. **服务可用性**：DuckDuckGo API 在中国大陆的访问不稳定，部分网络环境下超时率较高；
2. **搜索结果质量**：中文搜索的召回率和相关性不如百度等国内搜索引擎，影响了工具调用在中文场景下的实用性。

4.3 AGI 视角的思考

从通用人工智能（AGI）的发展视角审视本项目的实验结果，可以得出以下思考：

4.3.1 感知层到推理层的鸿沟

当前 VLM 主要工作在**感知层**——识别图片中的物体、文字、颜色等表层特征。然而，摘要总结（33.3%）和推理判断（60.0%）的结果表明，模型在需要**因果推理、全局理解和抽象归纳**的深层认知任务上仍存在显著不足。这反映了从”感知智能”到”认知智能”的跨越需要超越当前 Transformer 架构的能力——可能是更长的推理链（Chain-of-Thought）、外部知识增强（如 RAG）、或符号推理与神经网络的混合架构。

4.3.2 诚实性与对齐的权衡

失败案例分析揭示了一个有趣的现象：模型对”图中不存在 XX”的诚实回答被评测框架判为错误。这引出了一个更广泛的 AGI 对齐问题——我们希望 AI 诚实地报告它所看到的，还是猜测用户期望的答案？当前 VLM 的训练目标（最大化似然）天然倾向于生成”最可能的回答”而非”最准确的回答”。如何在诚实性与用户期望之间取得平衡，是多模态 AI 产品化过程中的核心挑战。

4.3.3 细粒度感知的物理极限

案例五（时钟读数）暴露了 VLM 在亚像素级视觉精度上的物理瓶颈。当前模型的图像编码器将图片压缩为固定分辨率（通常 512×512 或更小）的特征图，这

一压缩过程不可避免地丢失了毫米级的细节信息。实现人类水平的精细视觉感知，可能需要**可变分辨率编码、注意力引导的局部放大或多尺度特征融合**等架构创新。

4.4 改进方向

基于以上反思，提出三条具体的系统改进方向：

4.4.1 方向一：Sentence-BERT 语义嵌入替换哈希嵌入

将 RAG 模块的向量化方案从基于字符 n-gram 的 LSH 哈希替换为 Sentence-BERT 等预训练语义嵌入模型。预期收益：

- 语义匹配精度提升：从关键词级提升至语义级，支持同义词和概念关联检索；
- 多语言支持改善：多语言 Sentence-BERT 模型（如 paraphrase-multilingual-MiniLM）能更好处理中英文混合文档；
- 代价可控：轻量级 Sentence-BERT 模型（如 all-MiniLM-L6-v2，约 80MB）可在 CPU 上运行，无需 GPU。

4.4.2 方向二：LoRA 微调提升中文场景能力

在自建中文评测数据集上使用 LoRA（Low-Rank Adaptation）对 Qwen3-VL-Flash 进行轻量级微调。LoRA 仅训练低秩适配矩阵（参数量约为原模型的 1%），计算和存储成本极低。预期收益：

- 中文 OCR 准确率提升：通过微调中文专属的字体、排版数据，改善手写体和艺术字识别；
- 否定场景适应性：在训练数据中加入更多“图中没有 XX”的正确示例，使模型在否定回答场景下与评测期望对齐；
- 领域适配能力：可针对电商、教育、办公等特定场景构建领域 LoRA 模块，即插即用。

4.4.3 方向三：视频帧采样扩展至视频问答

将系统从静态图片问答扩展到短视频问答。技术路线：通过 OpenCV 等库对视频文件进行关键帧采样（如每秒 1 帧），逐帧调用 VLM 进行理解，再通过 LLM 对多帧结果进行时序聚合生成最终回答。预期可支持：

- 视频内容描述：“这段视频的主要事件是什么？”
- 时序关系推理：“事件 A 和事件 B 哪个先发生？”
- 动作识别：“视频中的人物在做什么？”

4.5 本章小结

本章从模型能力边界、系统工程局限、AGI 视角和具体改进方向四个层面进行了系统性反思。核心结论是：当前 VLM 在感知层（物体识别、OCR）已展现较强能力，但向认知层（推理、摘要、因果理解）的跨越仍面临显著挑战。通过语义嵌入升级、LoRA 微调和视频问答扩展三条改进路径，vlm-chat 系统有望在保持工程实用性的同时，持续提升对中文多模态语义的理解深度。